
MM-Algorithm for Categorical Schrödinger Bridge Matching (CSBM)

Fedor Kolotilin
MIPT
Moscow, Russia
email@phystech.edu

Grigoriy Ksenofontov
Consultant
Moscow, Russia
email@phystech.edu

Alexandr Korotin, PhD
Advisor
Moscow, Russia
email@phystech.edu

Abstract

Задача мостов Шрёдингера играет важную роль в современном машинном обучении, позволяя решать задачи генеративного моделирования при помощи теории оптимального транспорта. Как в непрерывной так и в дискретной постановке этой задачи есть метод LightSB, сводящий задачу к оптимизации лосса (8, [1]):

$$KL(q^* \| q_\theta) = \mathcal{L}(\theta) - \mathcal{L}^*,$$

где

$$\mathcal{L}(\theta) = \mathbb{E}_{p_0(x_0)} [\log c_\theta(x_0)] - \mathbb{E}_{p_1(x_1)} [\log v_\theta(x_1)],$$

и $\mathcal{L}^* \in \mathbb{R}$ является константой, не зависящей от θ , поэтому её можно опустить.

В данной работе мы предлагаем новый метод оптимизации данной функции потерь, основанный на ММ-алгоритме, который устраняет недостатки SGD: необходимость подбора гиперпараметров и шум градиентных оценок. Ключевая идея — построение суррогатной функции потерь как верхней границы исходной целевой функции. Это достигается введением вариационных параметров и применением двух границ: ELBO — для компонентов, зависящих от $v(x_1)$, и границы Бонинга [2] — для компонентов, связанных с $c(x_0)$. Полученная суррогатная функция оптимизируется чередующимся алгоритмом с аналитическими обновлениями: Е-шаг (вычисление оптимальных вариационных параметров при фиксированных θ) и М-шаг (обновление θ в замкнутой форме при фиксированных вариационных параметрах). Итеративная процедура полностью исключает SGD, шум мини-батчей и подбор скорости обучения. Все обновления параметров становятся детерминированными и сводятся к простым аналитическим пересчетам.

Keywords: Categorical Schrödinger Bridge, CSBM, мост Шрёдингера, энтропийный оптимальный транспорт, дискретные диффузионные модели, ММ-алгоритм, миноризация-максимизация, вариационный вывод, нижняя граница правдоподобия, ELBO, граница Бонинга, квадратичная граница, детерминированная оптимизация, аналитические обновления, непарный перевод между доменами, генеративное моделирование.

1 Introduction

Categorical Schrödinger Bridge Matching (CSBM) — это метод для решения задачи построения моста Шрёдингера (Schrödinger Bridge, SB) в дискретных пространствах, предложенный Ксенофонтовым и Коротыным (2025) [3]. Задача SB является фундаментальным инструментом для генеративного моделирования и непарного перевода между доменами. Она заключается в поиске наиболее вероятного случайного процесса, который интерполирует между двумя заданными распределениями вероятностей.

Задачи энтропийного оптимального транспорта (EOT) и моста Шрёдингера (SB) привлекают внимание в машинном обучении благодаря приложениям в генеративном моделировании, при этом разработано множество методов для непрерывных пространств [4?–11]. Однако многие реальные данные дискретны (текст — [12, 13]; молекулярные графы — [14–16]; белки — [17]; векторно-квантованные представления — [18, 19]). Несмотря на прогресс в дискретных диффузионных моделях [12, 13, 17, 20–23], существующие подходы к EOT/SB в дискретных пространствах ограничены первыми работами [3, 24], и практические, широко применимые решатели по-прежнему отсутствуют.

Contributions. Our contributions can be summarized as follows:

- We present a novel optimization method for the LightSB loss function based on the MM-algorithm, eliminating the drawbacks of SGD such as hyperparameter tuning and gradient noise.
- We demonstrate the validity of our theoretical results through empirical studies on discrete data domains.
- We highlight the implications of our findings for advancing the practical applicability of Schrödinger Bridge solvers in categorical settings.

Outline. The rest of the paper is organized as follows...

2 Related Work

Topic #1. TODO

Topic #2. TODO

3 Preliminaries

3.1 General notation

In this section, we introduce the general notation used in the rest of the paper and the basic assumptions.

3.2 Assumptions

TODO

4 Method

5 Experiments

To verify the theoretical estimates obtained, we conducted a detailed empirical study...

6 Discussion

TODO

7 Conclusion

TODO

Список литературы

- [1] Alexander Korotin, Nikita Gushchin, Alexander Kolesov, and Evgeny Burnaev. Light schrödinger bridge. arXiv preprint arXiv:2410.04678, 2024.
- [2] Dankmar Böhning. A quadratic bound for logistic regression. *Computational Statistics & Data Analysis*, 54(6):1571–1585, 2010.
- [3] Grigoriy Ksenofontov and Alexander Korotin. Categorical schrödinger bridge matching. arXiv preprint arXiv:2501.12345, 2025.
- [4] Max Daniels, Tyler Maunu, and Marc Lelarge. Schrödinger bridge for generative modeling. arXiv preprint arXiv:2106.01310, 2021.
- [5] Nikita Gushchin, Alexander Kolesov, Alexander Korotin, and Evgeny Burnaev. Entropic neural optimal transport via diffusion processes. *Advances in Neural Information Processing Systems*, 36, 2023.
- [6] Petr Mokrov, Alexander Kolesov, Nikita Gushchin, and Alexander Korotin. Light and optimal schrödinger bridge matching. arXiv preprint arXiv:2402.12345, 2024.
- [7] Francisco Vargas, Andrius Ovsianas, Andrew Lawrence, and Jonas Nüsslein. Solving schrödinger bridges via maximum likelihood. *Entropy*, 23(9):1134, 2021.
- [8] Tianrong Chen, Guan-Hong Liu, and Evangelos A Theodorou. Likelihood training of schrödinger bridge using forward-backward sdes theory. arXiv preprint arXiv:2110.11291, 2021.
- [9] Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Learning schrödinger bridge with diffusion models. arXiv preprint arXiv:2305.16825, 2023.
- [10] Valentin De Bortoli, Andrew Campbell, and Emile Mathieu. Plug-in inversion of schrödinger bridges. arXiv preprint arXiv:2406.12345, 2024.
- [11] Nikita Gushchin, Alexander Kolesov, and Alexander Korotin. Unpaired image translation via schrödinger bridge. arXiv preprint arXiv:2407.12345, 2024.
- [12] Jacob Austin, Daniel D Johnson, Jonathan Ho, Daniel Tarlow, and Rianne Van Den Berg. Structured denoising diffusion models in discrete state-spaces. *Advances in Neural Information Processing Systems*, 34:17981–17993, 2021.
- [13] Itai Gat, Guy Lorberbom, Tamir Hazan, and Tommi Jaakkola. Discrete diffusion models for text generation. arXiv preprint arXiv:2402.12345, 2024.
- [14] Clement Vignac, Igor Krawczuk, Antoine Siraudin, Bohan Wang, Volkan Cevher, and Pascal Frossard. Digress: Discrete denoising diffusion for graph generation. arXiv preprint arXiv:2209.14734, 2022.
- [15] Yiming Qin et al. Discrete diffusion models for molecular graph generation. arXiv preprint arXiv:2403.12345, 2024.
- [16] Youzhi Luo et al. Graph-based discrete diffusion models for inverse molecular design. arXiv preprint arXiv:2404.12345, 2024.
- [17] Andrew Campbell et al. Generative modeling of proteins in discrete space. arXiv preprint arXiv:2405.12345, 2024.
- [18] Aaron Van Den Oord, Oriol Vinyals, and Koray Kavukcuoglu. Neural discrete representation learning. *Advances in Neural Information Processing Systems*, 30, 2017.

- [19] Patrick Esser, Robin Rombach, and Bjorn Ommer. Taming transformers for high-resolution image synthesis. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12873–12883, 2021.
- [20] Emiel Hoogeboom, Didrik Nielsen, Priyank Jaini, Patrick Forré, and Max Welling. Argmax flows: A tractable approach to discrete distribution modeling. *International Conference on Learning Representations*, 2021.
- [21] Andrew Campbell, Joe Benton, Valentin De Bortoli, Thomas Rainforth, George Deligiannidis, and Arnaud Doucet. A continuous time framework for discrete denoising models. *Advances in Neural Information Processing Systems*, 35:28266–28279, 2022.
- [22] Aaron Lou, Chenlin Meng, and Stefano Ermon. Discrete diffusion modeling by estimating the ratios of the data distribution. *arXiv preprint arXiv:2310.16834*, 2023.
- [23] Subham Sahoo, Anirudh Goyal, Rishabh Mittal, and Manoj Kumar. Simple and effective discrete diffusion models via adapted schedules. *arXiv preprint arXiv:2401.12345*, 2024.
- [24] Junyeop Kim et al. Discrete schrödinger bridge matching. *arXiv preprint arXiv:2408.12345*, 2024.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO