
Light Schrödinger Bridge via closed - form optimization on discrete spaces

Fedor Kolotilin
Moscow, Russia

Grigoriy Ksenofontov
Moscow, Russia
Applied AI Institute, MIRAI

Alexandr Korotin, PhD
Moscow, Russia
Applied AI Institute, AXXX

Abstract

Задача мостов Шрёдингера играет важную роль в современном машинном обучении, позволяя решать задачи генеративного моделирования при помощи теории оптимального транспорта. Для качественного и одновременно быстрого решения этой задачи подходит метод LightSB [1], [2]. Интерес к данному методу обусловлен его простотой и вычислительной эффективностью: в отличие от большинства существующих подходов, LightSB не требует сложной оптимизации нескольких нейронных сетей и трудоемкого подбора гиперпараметров. Благодаря этому он позволяет получать решение за минуты на обычном процессоре, что делает его идеальным кандидатом для использования в качестве базового метода (baseline) при проведении экспериментов, а также для решения задач умеренной размерности, где применение более тяжеловесных алгоритмов избыточно.

В данной работе мы предлагаем новый метод решения статической задачи Моста Шрёдингера для дискретных пространств. Наша модель развивает идею модели D-lightSB, предложенные в работе (А. Коротина и др.) [1]. Мы модифицируем алгоритм поиска оптимального распределения, заменяя стохастический градиентный спуск на прямую оптимизацию ММ алгоритмом. Благодаря данной модификации мы избегаемся от необходимости подбора гиперпараметров и шума градиентных оценок в методе SGD. Все обновления параметров становятся детерминированными и сводятся к простым аналитическим вычислениям.

Keywords: мост Шрёдингера, энтропийный оптимальный транспорт, дискретные диффузионные модели, ММ-алгоритм, непарный перевод между доменами, генеративное моделирование.

1 Introduction

Задача SB является фундаментальным инструментом для генеративного моделирования и непарного перевода между доменами. Она заключается в поиске наиболее вероятного случайного процесса, который интерполирует между двумя заданными распределениями вероятностей.

Задачи энтропийного оптимального транспорта (EOT) и моста Шрёдингера (SB) привлекают внимание в машинном обучении благодаря приложениям в генеративном модели-

ровании, при этом разработано множество методов для непрерывных пространств [2–10]. Однако многие реальные данные дискретны (текст — [11, 12]; молекулярные графы — [13–15]; белки — [16]; векторно-квантованные представления — [17, 18]). Несмотря на прогресс в дискретных диффузионных моделях [11, 12, 16, 19–22], существующие подходы к ЕОТ/SB в дискретных пространствах ограничены первыми работами [23, 24], и практические, широко применимые методы по-прежнему отсутствуют.

Почти все существующие модели для ЕОТ и SB используют сложную параметризацию на основе нейронных сетей и множество гиперпараметров; они, как и ожидается, требуют больших вычислительных мощностей как для обучения, так и для предсказания. Хотя это неизбежно в крупномасштабных задачах генеративного моделирования, эти методы выглядят слишком тяжеловесными, когда пользователь просто хочет вычислить ЕОТ или SB между некоторыми распределениями данных умеренной размерности. Именно по этому в данной работе мы разрабатываем относительно простую модель, использующую простую и явную параметризацию и подбирающую оптимальные параметры при помощи ММ алгоритма.

Contributions. Наш вклад может быть описан следующим образом:

- Мы презентуем новый метод решения дискретной задачи SB. (дописать его ценность)
- теоретический вклад (доказали факт про то, про другое и про третье)
- практический вклад (алгоритм нахождения оптимальных параметров)

2 Problem statement

Формализуем генеративную задачу дискретного ЕОТ/SB: Это - хорошо известная проблема в литературе [23, 24]. Вкратце, цель состоит в том, чтобы изучить оптимальное условное распределение, которое переносит распределение вероятностей на дискретных пространствах, используя доступные эмпирические выборки. Формально мы рассматриваем следующую постановку:

Предполагается, что обучающий алгоритм имеет доступ к эмпирическим наборам данных $\{x_0^{(i)}\}_{i \in I_0}$ и $\{x_1^{(j)}\}_{j \in I_1}$, $x_0^{(i)}, x_1^{(j)} \in \mathcal{X}$, состоящим из независимых одинаково распределенных выборок из неизвестных распределений $p_0, p_1 \in \mathcal{P}(\mathcal{X})$, где $\mathcal{X}$ — дискретное пространство состояний. Затем задача состоит в том, чтобы использовать эти выборки для нахождения решения q^* задачи ЕОТ/SB между p_0 и p_1 для заданного эталонного распределения q^{ref} . Более того, решение должно поддерживать генерацию новых данных (out-of-sample generation), чтобы для любого нового x_0^{new} можно было сгенерировать $x_1^{\text{new}} \sim q^{\text{model}}(x_1 | x_0^{\text{new}})$.

Замечание. Данная работа не связана с дискретным ЕОТ, который включает такие методы решения, как алгоритм Синкхорна [25] или градиентные методы [26]. Эти подходы предназначены для негенеративной постановки задачи (см. Ksenofontov and Korotin [24], §2.3).

2.1 Динамический мост Шрёдингера

Исходная задача Шрёдингера (Schrödinger, 1931; 1932; Léonard, 2013) заключается в поиске процесса $q^* \in \mathcal{P}(\mathcal{X}^{N+2})$, интерполирующего между начальным распределением p_0 в момент времени $t_0 = 0$ и конечным распределением p_1 в момент времени $t_{N+1} = 1$. Это распределение находится путем минимизации дивергенции Кульбака–Лейблера (KL) относительно заданного марковского эталонного процесса $q^{\text{ref}} \in \mathcal{M}(\mathcal{X}^{N+2})$ при соблюдении маргинальных ограничений $p_0(x_0) = q(x_0)$ и $p_1(x_1) = q(x_1)$. В результате получается следующий оптимальный процесс:

$$q^* = \arg \min_{q \in \Pi_N(p_0, p_1)} \text{KL}(q(x_0, x_{\text{in}}, x_1) \| q^{\text{ref}}(x_0, x_{\text{in}}, x_1)),$$

где $\Pi_N(p_0, p_1) \subset \mathcal{P}(\mathcal{X}^{N+2})$ обозначает подмножество случайных процессов со значениями в $\mathcal{X}$, которые имеют маргинальные распределения p_0 и p_1 в моменты времени $t_0 = 0$ и $t_{N+1} = 1$ соответственно. Другими словами, динамическая задача Шрёдингера ищет случайный процесс q^* , который минимально отклоняется от эталонного процесса q^{ref} , соблюдая при этом граничные распределения p_0 и p_1 .

2.2 Статический мост Шрёдингера

Представленная выше динамическая задача SB также допускает статическую формулировку. Связь между ними начинается с наблюдения, что (1) допускает следующее разложение:

$$\min_{q \in \Pi_N(p_0, p_1)} [\text{KL}(q(x_0, x_1) \| q^{\text{ref}}(x_0, x_1)) + \mathbb{E}_{q(x_0, x_1)} \text{KL}(q(x_{\text{in}} | x_0, x_1) \| q^{\text{ref}}(x_{\text{in}} | x_0, x_1))] . \quad (2)$$

Далее заметим, что условное KL-слагаемое в (2) обращается в ноль, когда $q(x_{\text{in}} | x_0, x_1) = q^{\text{ref}}(x_{\text{in}} | x_0, x_1)$. Таким образом, мы ограничиваем q множеством процессов, удовлетворяющих этому условию. Это множество известно как reciprocal class процесса q^{ref} и обозначается $\mathcal{R}^{\text{ref}}(\mathcal{X}^{N+2}) \subset \mathcal{P}(\mathcal{X}^{N+2})$. При таком ограничении оптимизация сводится только к первому KL-слагаемому, что непосредственно приводит к статической задаче SB:

$$q^*(x_0, x_1) = \arg \min_{q \in \Pi(p_0, p_1)} \text{KL}(q(x_0, x_1) \| q^{\text{ref}}(x_0, x_1)) , \quad (3)$$

где $\Pi(p_0, p_1) \subset \mathcal{P}(\mathcal{X}^2)$ обозначает множество совместных распределений с маргинальными распределениями p_0 и p_1 , а $q^*(x_0, x_1)$ — оптимальное совместное распределение.

В данной статье мы будем работать только с статической постановкой задачи SB.

2.3 Loss функция

Основная идея модели заключается в восстановлении параметрической аппроксимации $q_\theta \approx q^*$ оптимального решения путём минимизации дивергенции Кульбака–Лейблера между q^* и q_θ :

$$\text{KL}(q^* \| q_\theta) \rightarrow \min_{\theta \in \Theta} . \quad (5)$$

Для оптимизации параметров θ мы следуем подходу [27]. А именно, мы выводим дискретную целевую функцию, которая эквивалентна прямой KL-целевой функции $\text{KL}(q^* \| q_\theta)$ с точностью до аддитивной константы. Важно, что это преобразование устраняет зависимость от неизвестного оптимального совместного распределения q^* и обеспечивает возможность практической оптимизации.

3 Related Work

Topic #1. TODO

Topic #2. TODO

4 Preliminaries

4.1 General notation

В этой секции мы представляем общую нотацию, которая будет использоваться до конца статьи и базовые предположения.

Рассмотрим дискретное пространство состояний $\mathcal{X} = \mathbb{S}^D$, где $\mathbb{S} = \{0, 1, \dots, S-1\}$ — множество из S категорий, а D — размерность. Каждый элемент $x \in \mathcal{X}$ представляет собой D -мерный вектор

$$x = (x^1, \dots, x^D).$$

Время дискретизируется как $\{t_n\}_{n=0}^{N+1}$ с $0 = t_0 < t_1 < \dots < t_N < t_{N+1} = 1$. Это даёт $N+2$ момента времени и определяет пространство траекторий $\mathcal{X}^{N+2}$ с кортежем $x_{\text{in}} := (x_{t_1}, \dots, x_{t_N}) \in \mathcal{X}^N$, собирающим промежуточные состояния. Множество $P(\mathcal{X}^{N+2})$ включает все дискретные по времени случайные процессы на пространстве траекторий, при этом $M(\mathcal{X}^{N+2}) \subset P(\mathcal{X}^{N+2})$ обозначает подмножество марковских процессов. Любой $q \in M(\mathcal{X}^{N+2})$ допускает прямое и обратное представления:

$$q(x_0, x_{\text{in}}, x_1) = q(x_0) \prod_{n=1}^{N+1} q(x_{t_n} | x_{t_{n-1}}) = q(x_1) \prod_{n=1}^{N+1} q(x_{t_{n-1}} | x_{t_n}).$$

Наконец, $q(\cdot | \cdot)$ используется для обозначения условных $(x_0 \rightarrow x_1)$ и переходных $(x_{t_{n-1}} \rightarrow x_{t_n})$ распределений.

4.2 Assumptions

TODO

5 Method

6 Experiments

To verify the theoretical estimates obtained, we conducted a detailed empirical study...

7 Discussion

TODO

8 Conclusion

TODO

Список литературы

- [1] Aleksei Leonov Iaroslav Sergeevich Koshelev Alexander Korotin Xavier Aramayo Carrasco, Grigoriy Ksenofontov. Entering the era of discrete diffusion models: A benchmark for schrödinger “ bridges and entropic optimal transport. arXiv:2509.23348, pages 7–8, 2025.
- [2] Evgeny Burnaev Alexander Korotin, Nikita Gushchin. Light schrödinger bridge. arXiv:2310.01174, 2024.
- [3] Max Daniels, Tyler Maunu, and Paul Hand. Score-based generative neural networks for large-scale optimal transport. In Advances in Neural Information Processing Systems 34 (NeurIPS 2021), volume 34, pages 12955–12965, 2021.
- [4] Nikita Gushchin, Alexander Kolesov, Alexander Korotin, Dmitry Vetrov, and Evgeny Burnaev. Entropic neural optimal transport via diffusion processes. In Advances in Neural Information Processing Systems 36 (NeurIPS 2023), 2023.

- [5] Nikita Gushchin, Daniil Selikhanovych, Sergei Kholkin, Evgeny Burnaev, and Alexander Korotin. Adversarial schrödinger bridge matching. In The Thirty-eighth Annual Conference on Neural Information Processing Systems (NeurIPS 2024), 2024. URL <https://openreview.net/forum?id=L3Knnigicu>.
- [6] Petr Mokrov, Alexander Korotin, Alexander Kolesov, Nikita Gushchin, and Evgeny Burnaev. Energy-guided entropic neural optimal transport. In The Twelfth International Conference on Learning Representations (ICLR 2024), 2024. URL <https://openreview.net/forum?id=d6tUsZeVs7>.
- [7] Francisco Vargas, Pierre Thodoroff, Austen Lamacraft, and Neil Lawrence. Solving schrödinger bridges via maximum likelihood. *Entropy*, 23(9):1134, 2021.
- [8] Tianrong Chen, Guan-Horng Liu, and Evangelos Theodorou. Likelihood training of schrödinger bridge using forward-backward SDEs theory. In International Conference on Learning Representations (ICLR 2021), 2021.
- [9] Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion schrödinger bridge matching. In Thirty-seventh Conference on Neural Information Processing Systems (NeurIPS 2023), 2023. URL <https://openreview.net/forum?id=qy070HsJT5>.
- [10] Valentin De Bortoli, Iryna Korshunova, Andriy Mnih, and Arnaud Doucet. Schrödinger bridge flow for unpaired data translation. In The Thirty-eighth Annual Conference on Neural Information Processing Systems (NeurIPS 2024), 2024. URL <https://openreview.net/forum?id=1F32iCJFfa>.
- [11] Jacob Austin, Daniel D Johnson, Jonathan Ho, Daniel Tarlow, and Rianne Van Den Berg. Structured denoising diffusion models in discrete state-spaces. In *Advances in Neural Information Processing Systems 34* (NeurIPS 2021), volume 34, pages 17981–17993, 2021.
- [12] Itai Gat, Tal Remez, Neta Shaul, Felix Kreuk, Ricky TQ Chen, Gabriel Synnaeve, Yossi Adi, and Yaron Lipman. Discrete flow matching. In The Thirty-eighth Annual Conference on Neural Information Processing Systems (NeurIPS 2024), 2024.
- [13] Clement Vignac, Igor Krawczuk, Antoine Siraudin, Bohan Wang, Volkan Cevher, and Pascal Frossard. Digress: Discrete denoising diffusion for graph generation. *arXiv preprint arXiv:2209.14734*, 2022.
- [14] Yiming Qin, Manuel Madeira, Dorina Thanou, and Pascal Frossard. Defog: Discrete flow matching for graph generation. *arXiv preprint arXiv:2410.04263*, 2024.
- [15] Xiaoshan Luo, Zhenyu Wang, Jian Lv, Lei Wang, Yanchao Wang, and Yanming Ma. Crystalflow: A flow-based generative model for crystalline materials. *arXiv preprint arXiv:2412.11693*, 2024.
- [16] Andrew Campbell, Joe Benton, Valentin De Bortoli, Thomas Rainforth, George Deligiannidis, and Arnaud Doucet. A continuous time framework for discrete denoising models. In *Advances in Neural Information Processing Systems 35* (NeurIPS 2022), volume 35, pages 28266–28279, 2022.
- [17] Aaron Van Den Oord, Oriol Vinyals, et al. Neural discrete representation learning. In *Advances in Neural Information Processing Systems 30* (NeurIPS 2017), volume 30, 2017.
- [18] Patrick Esser, Robin Rombach, and Bjorn Ommer. Taming transformers for high-resolution image synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2021)*, pages 12873–12883, 2021.
- [19] Emiel Hoogeboom, Didrik Nielsen, Priyank Jaini, Patrick Forre, and Max Welling. Argmax flows and multinomial diffusion: Learning categorical distributions. In *Advances in Neural Information Processing Systems 34* (NeurIPS 2021), volume 34, pages 12454–12465, 2021.

- [20] Aaron Lou, Chenlin Meng, and Stefano Ermon. Discrete diffusion language modeling by estimating the ratios of the data distribution. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*, 2023.
- [21] Subham Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin Chiu, Alexander Rush, and Volodymyr Kuleshov. Simple and effective masked diffusion language models. In *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*, volume 37, pages 130136–130184, 2024.
- [22] Andrew Campbell, Jason Yim, Regina Barzilay, Tom Rainforth, and Tommi Jaakkola. Generative flows on discrete state-spaces: Enabling multimodal flows with applications to protein codesign. In *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*, volume 235 of *Proceedings of Machine Learning Research*, pages 5453–5512, 2024. URL <https://proceedings.mlr.press/v235/campbell124a.html>.
- [23] Jun Hyeong Kim, Seonghwan Kim, Seokhyun Moon, Hyeongwoo Kim, Jeheon Woo, and Woo Youn Kim. Discrete diffusion schrödinger bridge matching for graph transformation. *arXiv preprint arXiv:2410.01500*, 2024.
- [24] Grigoriy Ksenofontov and Alexander Korotin. Categorical schrödinger bridge matching. In *Forty-second International Conference on Machine Learning (ICML 2025)*, 2025. URL <https://openreview.net/forum?id=RBly0n0r2h>.
- [25] Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in Neural Information Processing Systems 26 (NeurIPS 2013)*, 26, 2013.
- [26] Pavel Dvurechensky, Alexander Gasnikov, and Alexey Kroshnin. Computational optimal transport: Complexity by accelerated gradient descent is better than by sinkhorn’s algorithm. In *International Conference on Machine Learning (ICML 2018)*, pages 1367–1376. PMLR, 2018.
- [27] Alexander Korotin, Nikita Gushchin, and Evgeny Burnaev. Light schrödinger bridge. In *The Twelfth International Conference on Learning Representations (ICLR 2024)*, 2024.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO